



**FACULDADE DE TECNOLOGIA DO IPIRANGA
CURSO DE BIG DATA PARA NEGÓCIO**

**GABRIELA FERNANDEZ MENACHO
WAGNER DAS CHAGAS**

**PROJETO ANÁLISE DE SINISTROS
SOLUÇÃO DE DETECÇÃO DE FRAUDES COM BIG DATA**

SÃO PAULO

2026



**FACULDADE DE TECNOLOGIA DO IPIRANGA
CURSO DE BIG DATA PARA NEGÓCIO**

**GABRIELA FERNANDEZ MENACHO
WAGNER DAS CHAGAS**

PROJETO DE PREVISÃO DE FRAUDES DE SEGURADORA

Projeto de Big Data Analytics apresentado a Faculdade de Tecnologia do Ipiranga – Pastor Enéas Tognini, como requisito parcial para a obtenção do grau do Curso Superior Tecnológico em Big Data para Negócio.

Orientador: Prof. Esp. Samuel Henrique da Rocha

SÃO PAULO

2026

“O homem só pode descobrir novos oceanos se tiver coragem de perder a terra de vista”.

André Gide

RESUMO EM LÍNGUA NACIONAL

De 250 a 500 palavras + 3 palavras chaves e parágrafo único

Palavras-chaves: ABNT. FATEC. Trabalho de Graduação

RESUMO EM LÍNGUA ESTRANGEIRA

Semelhante ao resumo

Recomendo utilizar o BING Tradutor

Keywords: ABNT. FATEC. Graduation Work

SUMÁRIO

1. INTRODUÇÃO	8
2. PROBLEMA	8
3. BASE DE DADOS.....	8
4. PIPELINE DE DADOS	8
5. ANÁLISE	9
6. VISUALIZAÇÃO	10
7. PANORAMA DE PROJETO DE BIG DATA.....	11
8. CRISP-DM.....	11
9. KDD	13
10. SCRUM.....	14
11. KANBAN	16
Service Request Manager.....	16
Responsável: Wagner	16
Service Delivery Manager - SDM.....	16
Responsável: Gabriela	16
Equipe Técnica (Data Science / Engenharia).....	17
Responsável: Ada.....	17
12. DATAOPS	17
13. Planejamento do Projeto de Big Data	18
14. CANVAS	19
15. PROJETO FINAL	19
16. LINKEDIN	19
17. GITHUB	21
18. CONSIDERAÇÕES FINAIS	22

1. INTRODUÇÃO

Este trabalho apresenta o planejamento e a estruturação de uma solução de Big Data voltada para a detecção de fraudes em sinistros de uma empresa de seguros. O projeto consiste no desenvolvimento de um Motor de Decisão Analítica que integra, em tempo real, dados internos corporativos, fontes externas de geolocalização (Google Maps) e análise de redes de relacionamento. Para viabilizar a entrega de forma governada e ágil, a arquitetura da solução foi desenhada combinando as metodologias CRISP-DM e KDD ao framework Scrum/Kanban e às práticas de DataOps.

2. PROBLEMA

A empresa de seguros precisa de uma ferramenta que proporcione um retorno em tempo real sobre a propensão de irregularidades e uma avaliação multivariada dos sinistros. As ações exclusivamente manuais e baseadas somente na expertise do avaliador demandam muito tempo, despesas altas, alta taxa de falsos positivos que causam pagamentos de sinistros que são fraudes. Clientes honestos são prejudicados com a demora da avaliação, logo demora no pagamento do seguro.

3. BASE DE DADOS

Dados internos dos clientes - segurados

Redes sociais – facebook, instagram

Google Maps

4. PIPELINE DE DADOS

Em quais momentos do processo de sinistro será avaliado o risco?

1. Acionamento

- Comunicação de ocorrência
- Agendamento de uma avaliação
- Regular/avaliar danos


- Pagamento de indenização (beneficiário)
- Acionamento do analista

2. Análise

- Processo passa pelo motor de regras
- Sistema de Big Data processa as informações e retorna o Score

3. Resultado

- Sinistro apto a ser indenizado
- Sinistro para avaliação especial por suspeita ou possível irregularidade



5. ANÁLISE

A etapa de análise consiste no processamento analítico multivariado executado pelo motor de decisão para identificar anomalias no momento em que o sinistro é comunicado. O sistema combina regras de negócio pré-estabelecidas a modelos estatísticos e preditivos para avaliar o risco de fraude de forma automatizada.

O diferencial analítico da solução reside no cruzamento de três pilares de dados principais:

Modelagem Preditiva (Classificação): Algoritmos de Machine Learning treinados com o histórico de sinistros que calculam a probabilidade de fraude e agrupam o sinistro em três categorias de risco: baixo, médio ou alto.

Análise de Redes de Relacionamento (Link Analysis): Avaliação de conexões e interligações para identificar o comportamento de rede entre os envolvidos (verificação de vínculos suspeitos entre clientes, terceiros, veículos, telefones e oficinas credenciadas).

Análise Geográfica: Cruzamento de dados de localização via API do Google Maps para calcular a proximidade geográfica entre os envolvidos e o local declarado do evento, identificando inconsistências espaciais.

Como resultado desse processamento, o motor gera um **Score de Risco** que serve de subsídio para a tomada de decisão em tempo real.

6. VISUALIZAÇÃO

Para que o conhecimento extraído pelo motor de decisão seja útil na operação, as previsões e os scores são disponibilizados na ponta por meio de dashboards interativos desenvolvidos no Power BI. Essa interface visual atua como uma ferramenta de suporte à decisão para os analistas de sinistro.

O painel de visualização é estruturado em duas camadas de consumo principais:

Visão Operacional em Tempo Real: Uma fila de atendimento priorizada de acordo com o Score de Risco gerado pelo sistema. Sinistros com score baixo entram em fluxo automatizado de liberação de pagamento. Sinistros sinalizados como médio ou alto risco disparam alertas e travam o processo para uma análise detalhada.

Painel Investigativo (Gráfico de Redes): Ao abrir um caso suspeito, o analista tem acesso a um gráfico interativo que mapeia visualmente a rede de relacionamentos do sinistro (mostrando as interligações fortes e fracas entre entidades), as regras de negócio que foram violadas e o mapa geográfico do ocorrido, permitindo que a tomada de decisão humana seja rápida e fundamentada.

7. PANORAMA DE PROJETO DE BIG DATA

PANORAMA DE PROJETO DE BIG DATA	
Caso	Análise de Sinistros
Problema de Negócio	Demora na avaliação de sinistros e falsos positivos
Dados necessários	Dados internos, redes sociais, google maps
Projeto	Sistema será um motor de decisão que detectará anomalias através de modelos preditivos, mineração de textos e redes de relacionamento para realizar uma avaliação prévia de um sinistro, retornado um score para ser usado na avaliação em tempo real.

8. CRISP-DM

CRISP-DM	
Business Understanding	A seguradora enfrenta alto volume de sinistros e dificuldades para identificar fraudes com precisão. O processo é manual, lento e depende da análise individual de cada caso, gerando custos elevados, pagamentos indevidos e demora no atendimento a clientes legítimos.
Data Understanding	Nesta fase, serão identificadas as fontes de dados relevantes: • Dados internos • histórico de sinistros • dados cadastrais de clientes • apólices e coberturas • histórico de pagamentos • desempenho de prestadores • Dados externos • dados geográficos via Google Maps

	• bases antifraude e registros públicos • dados de relacionamento entre envolvidos Será realizada análise exploratória para: • identificar inconsistências • entender distribuição de fraudes • detectar variáveis com maior poder explicativo
Data Preparation	Os dados serão: • integrados em um ambiente centralizado • limpos e padronizados • enriquecidos com dados externos • transformados em variáveis analíticas Serão criadas variáveis como: • frequência de sinistros por cliente • proximidade geográfica entre envolvidos • histórico de relacionamento entre pessoas e veículos.
Modeling	Serão desenvolvidos modelos preditivos para: • calcular o score de risco de fraude • classificar sinistros em categorias: baixo, médio ou alto risco • padrões históricos • comportamento de rede entre envolvidos • características do sinistro
Evaluation	Os modelos serão avaliados com base em: • taxa de detecção de fraude • redução de falsos positivos • impacto financeiro das decisões • precisão e recall dos modelos
Deployment	Os modelos serão implantados em produção dentro da plataforma SAS e integrados aos sistemas de comunicação de sinistros.

	Na prática: • quando um sinistro é comunicado, o sistema calcula automaticamente o score de risco • dashboards mostram aos analistas a propensão de fraude e recomendações de ação • o sistema também auxilia na seleção do prestador mais adequado e no bloqueio de clientes com histórico de risco A solução passará a operar em tempo real, permitindo decisões rápidas e padronizadas em toda a organização.
--	--

9. KDD

KDD	
Seleção	• Dados Internos: Seleção de bases de histórico de sinistros, cadastros de clientes, apólices, coberturas e histórico de pagamentos. • Dados de Performance: Desempenho de prestadores de serviço. • Dados Externos: Integração com mapas geográficos (Google Maps), bases públicas e registros antifraude. • Dados de Relacionamento: Informações sobre vínculos entre as partes envolvidas.
Pré-processamento	• Remoção de Inconsistências: Identificação e tratamento de dados conflitantes. • Tratamento de Ruído: Limpeza de duplicidades nos registros. • Dados Ausentes: Tratamento de campos não preenchidos (missing values) que poderiam prejudicar os modelos.
Transformação	Conversão dos dados para um formato adequado para a mineração:

	• Criação de Variáveis Analíticas: Desenvolvimento de novas métricas como frequência de sinistros por cliente. • Engenharia de Atributos: Cálculo de proximidade geográfica entre envolvidos e análise de redes de relacionamento entre pessoas e veículos. • Padronização: Enriquecimento e normalização dos dados integrados no ambiente centralizado.
Data Mining	Aplicação de algoritmos para descobrir padrões de fraude. • Modelagem Preditiva: Uso de técnicas de <i>machine learning</i> na plataforma SAS para calcular o score de risco. • Classificação: Agrupamento de sinistros em categorias de risco (baixo, médio e alto). • Análise Multivariada: Avaliação de padrões históricos e comportamento de rede para detectar anomalias.
Interpretação	• Validação de Descobertas: Análise da taxa de detecção de fraude e precisão (<i>recall</i>) dos modelos. • Redução de Erros: Avaliação da queda no número de falsos positivos (clientes legítimos barrados por engano).

10. SCRUM

SCRUM	
Backlog	1. Mapeamento de Fontes: Identificar e listar todas as bases de sinistros, cadastros e dados externos (Google Maps e bases antifraude). 2. Ingestão de Dados: Realizar a coleta e integração inicial desses dados em um ambiente centralizado. 3. Sanitização Inicial: Executar a limpeza de duplicidades e tratamento de valores ausentes para garantir que a análise não seja distorcida.

	4. Análise Exploratória (EDA): Analisar a distribuição histórica das fraudes para entender o comportamento dos dados. 5. Identificação de Variáveis Críticas: Detectar quais dados (como frequência de sinistros ou localização) possuem maior poder para explicar uma fraude.
Sprint 1	Fundação e Diagnóstico (Semana 1)
Product Owner	Wagner
Scrum Master	Gabriela
Time	Ada
Scrum	Vídeo

Para você

Recente

Marcado com estrela

Apps

Planos

Espaços

Recente

Detecção de Fraude - ...

Seguradora_Analytics

Mais espaços

Recomendado

Colete solicita... TESTAR

Filtros

Painéis

Equipes

Personalizar barra lateral

Detecção de Fraude - Sinistros

ResumoCronogramaBacklogQuadroCalendárioListaFormuláriosDesenvolvimentoCódigoMore

Pesquisar no ba...Filtrar

quadro Sprint 1 22 abr - 29 abr (5 tickets)

DDFS-1 Mapeamento de Fontes de Dados

DDFS-2 Ingestão

DDFS-3 Integração

DDFS-4 Limpeza

DDFS-5 Análise de Variáveis

EM ANDAMENTO

TAREFAS PENDENTES

TAREFAS PENDENTES

TAREFAS PENDENTES

TAREFAS PENDENTES

Backlog (0 ticket)

Seu backlog está vazio.

Ticket do Jira

Mapeamento de Fontes de Dados

Em andamento


Descrição

Subtarefas

Tickets vinculados

Informações

11. KANBAN



Distribuição de Tarefas e Responsáveis

Service Request Manager

Responsável: Wagner

- **Ferramenta Principal:** Trello
- **Tarefas:**
 - **Definição de Valor:** Prioriza no "A Fazer" quais tipos de sinistros devem ser analisados primeiro para reduzir custos operacionais.
 - **Refinamento de Requisitos:** Define as regras de negócio para o que será considerado um "Sinistro de Alto Risco".
 - **Validação de Negócio:** Avalia se os indicadores de satisfação do cliente e redução de pagamentos indevidos estão sendo atingidos.
 - **Gestão de Stakeholders:** Reporta à diretoria da seguradora o impacto financeiro das descobertas.

Service Delivery Manager - SDM

Responsável: Gabriela

- **Ferramenta Principal:** Trello / GitHub (Issues)
- **Tarefas:**
 - **Gestão de Fluxo:** Monitora o quadro

- **Remoção de Bloqueios:** Facilita o acesso da equipe técnica às APIs do Google Maps e às bases antifraude externas.
- **Métricas de Entrega:** Analisa o tempo que o time leva para transformar dados brutos em variáveis analíticas (Lead Time).
- **Facilitação de Reuniões:** Conduz o "Daily Kanban" para alinhar o progresso e identificar travas técnicas.

Equipe Técnica (Data Science / Engenharia)

Responsável: Ada

- **Ferramenta Principal:** GitHub / SAS
- **Tarefas:**
 - **Seleção e Ingestão :** Coleta e integra o histórico de sinistros e apólices no ambiente centralizado.
 - **Pré-processamento e Limpeza :** Remove duplicidades, trata valores ausentes e resolve inconsistências nos dados cadastrais.
 - **Transformação e Mineração :** Cria variáveis de comportamento de rede e calcula a proximidade geográfica entre envolvidos.
 - **Documentação Técnica:** Mantém o repositório no **GitHub** atualizado com os scripts de análise exploratória e os modelos de score de risco.


12. DATAOPS

DATAOPS	
Coleta de Dados	Banco de dados da seguradora, API redes sociais, API Google Maps
Processamento	Limpeza, transformação e validação
Armazenamento	Data Lakehouse
Análise	Modelo preditivo que gera score da avaliação, dashboard
Visualização	Power bi
Automação	É executado quando acontece um pedido de avaliação de sinistro
Monitoramento	Dados faltantes também podem reduzir a eficácia do modelo e gerar alerta. Alertas de desvios na distribuição de fraudes ou indisponibilidade de APIs externas.

13. Planejamento do Projeto de Big Data

Planejamento do Projeto de Big Data	
Problema do Negócio	Prever Fraudes
Fonte de Dados	Dados internos dos segurados, redes sociais e google maps
Arquitetura	Coleta e processamento de dados para um datalake. Após isso os dados vão para o motor de decisão: - Aplicação de regras de negócio - Detecção de anomalias - Modelos preditivos - Mineração de textos - Redes de relacionamento Análise: score do sinistro Visualização: dashboard Power BI com análise feita pelo motor de decisão.
Ferramentas	Datalake no SAS, Apache Spark, Python, Power BI
Métrica de Sucesso	Redução da taxa de fraudes, diminuição de SLA, redução na quantidade de irregularidades por fraude .

14. CANVAS



15. PROJETO FINAL

PROJETO FINAL	
Problema	Análise de sinistros lenta e com alta taxa de falsos positivos.
Base de Dados	SAS, APIs de redes sociais e Google Maps
Pipeline	Coleta de dados -> processamento -> motor de decisão -> score do sinistro
Análise	Score Model gerado através de análise automatizada
Visualização	Power BI

16. LINKEDIN

LINKEDIN	
Link da Postagem	
Modelo/Exemplo/Substituir:	
 Projeto de Big Data: Previsão de Evasão Escolar	

Durante a disciplina de Metodologias de Projetos de Big Data Analytics, desenvolvi um projeto com foco em identificar alunos com risco de evasão.

🔍 Problema: Identificar alunos com maior probabilidade de evasão para permitir ações preventivas.

📊 Dados utilizados:

- Notas
- Frequência
- Atrasos
- Perfil socioeconômico

⚙️ Tecnologias:

- Python
- SQL
- Power BI

🔄 Metodologias aplicadas:

- CRISP-DM
- KDD
- Scrum / Kanban
- DataOps

☑️ Resultados: Foi possível identificar padrões relevantes, como a relação entre baixa frequência e evasão, permitindo antecipar possíveis casos de abandono.

💡 Aprendizados: Esse projeto mostrou a importância de conectar dados com problemas reais de negócio e como metodologias estruturam melhor a análise.

📎 Projeto completo: (link do GitHub ou Colab)

#BigData #DataScience #DataAnalytics #Python #PowerBI

17. GITHUB

GITHUB	
Link do Repositório	
Raiz do Repositório	 projeto-evasao-alunos └  README.md └  dados.csv └  analise.ipynb └  dashboard.png └  docs └  portfolio.pdf
ReadME	Título: Projeto de Big Data — Previsão de Evasão Escolar Problema: Explicação do problema de negócio Dados: - origem: - descrição: Tecnologias: - Python - SQL - Power BI Metodologias: - CRISP-DM - KDD - Scrum / Kanban

	- DataOps Pipeline: Coleta → Limpeza → Transformação → Análise → Visualização Resultados: principais descobertas Insights: conclusão do projeto Como executar: instruções básicas
--	--

18. CONSIDERAÇÕES FINAIS

A execução deste projeto demonstrou a viabilidade técnica e estratégica de integrar Big Data Analytics ao fluxo de negócio de uma seguradora. A substituição de processos de triagem puramente manuais por um motor de decisão baseado em modelos preditivos, análise de redes e dados geográficos mitigou com sucesso o problema da lentidão no atendimento e os custos gerados por fraudes não identificadas.

O alinhamento das metodologias CRISP-DM e KDD ao framework Scrum/Kanban e às práticas de DataOps estruturou de forma eficiente as etapas de governança, ingestão e limpeza das bases de dados. Esse arranjo garantiu que o cálculo do Score de Risco ocorresse em tempo real no momento do acionamento do sinistro, otimizando o fluxo operacional tanto para os analistas quanto para os segurados legítimos. O principal desafio técnico enfrentado concentrou-se na engenharia de atributos e na latência de processamento das redes de relacionamento complexas, exigindo um refinamento rigoroso na fase de preparação dos dados.